


Hệ Thống Cá Nhân Hóa Giao Tiếp

Dựa trên mô hình ngôn ngữ lớn (LLM) tại thiết bị đầu cuối thông qua tổng hợp ngữ cảnh và đặc điểm hành vi.



LĨNH VỰC



AI & NLP

ỨNG DỤNG



Smart Reply

Lĩnh Vực & Vấn Đề Kỹ Thuật

Hệ thống cá nhân hóa giao tiếp trên thiết bị di động sử dụng mô hình ngôn ngữ lớn (LLM)



PRIVACY

Rủi Ro Bảo Mật

Dữ liệu hội thoại phải gửi lên Cloud để xử lý, gây rủi ro bảo mật cho người dùng.

VẤN ĐỀ

Thiếu tính riêng tư



CONTEXT

Thiếu Ngữ Cảnh

Gợi ý thường dựa trên câu tin nhắn cuối cùng thay vì toàn bộ luồng hội thoại.

VẤN ĐỀ

Gợi ý phi ngẫu nhiên



PERSONA

Thiếu Cá Nhân Hóa

Gợi ý mang tính "máy móc", không phản ánh văn phong, cảm xúc hay tính cách của người dùng.

VẤN ĐỀ

Không có phong cách riêng

Kiến Trúc Tổng Thể

Hệ thống cá nhân hóa giao tiếp trên thiết bị đầu cuối với lớp trung gian Context-Persona Mediation Layer



Context Graph Construction Engine

- ✓ Biểu diễn ngữ cảnh dạng đồ thị động
- ✓ Tránh phụ thuộc độ dài token
- ✓ Trích xuất tiêu đồ thị suy diễn

ENGINE #1



Persona Representation & Adaptation Module

- ✓ Vector đa thành phần tính cách
- ✓ Phong cách từ vựng, cú pháp
- ✓ Tham số thích nghi nhẹ

MODULE #2



Adaptive Inference Controller

- ✓ Điều phối hành vi sinh LLM
- ✓ Temperature động
- ✓ Ràng buộc decoding

CONTROLLER #3



Implicit Feedback Learning Loop

- ✓ Học không cần phản hồi tường minh
- ✓ Thu thập tín hiệu ngầm
- ✓ Cập nhật persona liên tục

LEARNING #4



Context-Persona Mediation Layer

Lớp trung gian điều phối LLM theo ngữ cảnh và hành vi người dùng



Thành Phần Chính (Phần 1)

Kiến trúc hệ thống với hai thành phần cốt lõi xử lý ngữ cảnh và cá nhân hóa



Context Graph Construction Engine

MÔ HÌNH HÓA NGỮ CẢNH

🎯 Mục tiêu

Thay thế sliding window tuyến tính bằng biểu diễn đồ thị động, tránh phụ thuộc độ dài token

⚙️ Cơ chế kỹ thuật

- **Node:** Đoạn hội thoại, thực thể, hành động giao tiếp
- **Edge:** Quan hệ ngữ nghĩa, thời gian, vai trò người tham gia
- **Relevance Score:** Dựa trên khoảng cách thời gian, tương đồng ngữ nghĩa, tần suất phản hồi
- **Subgraph:** Trích xuất tiểu đồ thị thay vì chuỗi liên tục



Persona Representation & Adaptation Module

MÔ HÌNH HÓA TÍNH CÁCH

🎯 Mục tiêu

Tạo ra biểu diễn "tính cách giao tiếp" tách biệt khỏi LLM gốc

⚙️ Biểu diễn Persona

- **Vector đa thành phần:** Phong cách từ vựng, cấu trúc cú pháp
- **Thói quen biểu cảm:** Emoji, viết tắt
- **Mức độ trang trọng:** Theo từng loại đối tượng giao tiếp

🔄 Cơ chế thích nghi

- Prompt conditioning vector, Adapter layer weights
- Attention bias coefficients
- Cập nhật từ tin nhắn người dùng gửi đi, không cần cloud

Thành Phần Chính (Phần 2)

Điều phối suy diễn và học tập từ phản hồi ngầm để tối ưu hóa cá nhân hóa



Adaptive Inference Controller

ĐIỀU PHỐI SUY DIỄN

🎯 Mục tiêu

Điều phối hành vi sinh của LLM theo ngữ cảnh + persona + ý định người dùng

⚙️ Cơ chế điều phối

- **Xác định trước khi gọi LLM:** Mục đích suy diễn, mức độ can thiệp, ngưỡng sáng tạo
- **Dynamic Temperature:** Điều chỉnh độ ngẫu nhiên theo ngữ cảnh
- **Attention Masking:** Ưu tiên ngữ cảnh quan trọng
- **Decoding Constraints:** Ràng buộc theo persona người dùng



Implicit Feedback Learning Loop

HỌC TỪ PHẢN HỒI

🎯 Mục tiêu

Học cá nhân hóa không cần phản hồi tường minh từ người dùng

⚙️ Nguồn tín hiệu ngầm

- **Suggestion Selection:** Gợi ý được chọn hay bỏ qua
- **Editing Level:** Mức độ chỉnh sửa sau khi chọn gợi ý
- **Response Time:** Thời gian từ gợi ý đến khi gửi
- **Deletion Behavior:** Xóa gợi ý ngay sau khi hiển thị

➔ Cập nhật

- Tín hiệu ánh xạ thành điểm cập nhật persona
- Điều chỉnh chiến lược suy diễn tự động

Tối Ưu Hóa & Quy Trình Vận Hành

Hệ thống vận hành hoàn toàn trên thiết bị đầu cuối với quy trình tối ưu hóa liên tục



Tối Ưu Trên Thiết Bị

- **LLM:** Mô hình nén/lượng tử hóa
- **Thực thi:** NPU/GPU
- **Lưu trữ:** Persona & Context Graph cục bộ
- **Khác:** Không đồng bộ cloud



Lợi Thế Kỹ Thuật

- ✓ Bảo mật dữ liệu tuyệt đối
- ✓ Độ trễ thấp, phản hồi nhanh
- ✓ Không phụ thuộc internet
- ✓ Tiết kiệm chi phí băng thông

1 INPUT

Người dùng nhận tin nhắn hoặc bắt đầu soạn thảo

2 PROCESSING

- Truy xuất ngữ cảnh từ bộ nhớ cục bộ
- Áp dụng "Personalized Layer" vào LLM gốc

3 INFERENCE

LLM tạo gợi ý dựa trên **Ngữ cảnh + Tính cách người dùng**

OUTPUT

- ✓ Hiển thị gợi ý dạng bong bóng
- ✓ Tự động hoàn thiện văn bản trên bàn phím

5 FEEDBACK LOOP

Nếu chọn gợi ý → **Ghi nhận để tối ưu hóa** mô hình cá nhân hóa



Quy trình lặp liên tục